

附加讲义：算力估算与 KataGo 进化范式

为了向高性能计算与物理背景的罗院士讲解，本讲义对 AlphaGo Zero 的模型参数量与推理算力（MCTS 评估次数）进行了严格的量级估算，并系统梳理了开源社区（尤其是 KataGo）对这种“算力黑洞”进行的降维打击优化。

一、AlphaGo Zero 模型参数量精算

1. 网络结构拆解（以 20 ResBlock 版本为例）

AlphaGo Zero 的核心是一个共享特征提取层的双头残差网络（ResNet），通道数统一为 256。

- **输入层：** $19 \times 19 \times 17$ 的图像。初始卷积层为 $3 \times 3 \times 256$ 。参数量：
 $17 \text{ (in)} \times 256 \text{ (out)} \times 3 \times 3 = 39,168$
- **残差块 (20个)：** 每个 Block 包含 2 个 3×3 卷积层。
单层参数： $256 \times 256 \times 3 \times 3 \approx 589,824$
单块参数： $589,824 \times 2 \approx 1.18 \times 10^6$ (118万)
20块总计： $1.18\text{M} \times 20 \approx 23,592,960$ (2359万)
- **策略头 (Policy Head)：** 1个 1×1 卷积 (降到2通道) + 全连接到 362 (361个交叉点+1个 pass)。
卷积： $256 \times 2 \times 1 \times 1 = 512$
FC层： $(2 \times 19 \times 19) \times 362 = 722 \times 362 \approx 261,364$
共计：约 26 万
- **价值头 (Value Head)：** 1个 1×1 卷积 (降到1通道) + FC(256) + FC(1)。
卷积： $256 \times 1 \times 1 \times 1 = 256$
FC1： $(1 \times 19 \times 19) \times 256 = 361 \times 256 = 92,416$
FC2： $256 \times 1 = 256$
共计：约 9 万

2. 宏观结论

模型版本	总参数量	训练总局数
AGZ (3天版) - 20个残差块	~2400 万 (24M)	490 万局
AGZ (40天版) - 40个残差块	~4750 万 (47.5M)	2900 万局

对比：GPT-3 有 1750亿，目前大语言模型动辄千亿参数；AlphaGo Zero 是典型的“小模型、巨算力”，算力绝大多数被消耗在了搜索（推理）过程，而非单次前向传播。

二、算力黑洞：天文数字的推理次数估算

自我强化学习之所以极度耗费算力，是因为生成一条训练数据需要极其庞大的 MCTS 模拟，每次模拟都需要调用一次神经网络（评估叶节点）。

计算公式：训练过程中的推理（评估）总次数

Total Inferences = Total Games × Moves per Game ×
Simulations per Move

以 AlphaGo Zero (3天 20-block 版本) 为例：

- 生成总局数 (Total Games)：4,900,000 局
- 每局平均步数 (Moves/Game)：围棋平均约 200 步（走到终局或投降）
- 每步 MCTS 模拟数 (Sims/Move)：1,600 次

算力爆炸：

$4,900,000 \times 200 \times 1,600 = 1,568,000,000,000$

≈ 1.56 万亿次网络前向推理！
(1.56 × 10¹²)

如果算上 40 天的 40-block 版本，推理次数高达 **9.28 万亿次**。每一次推理都需要计算一个 24M~47M 参数的 ResNet（单次推理约百亿 FLOPs，即 10 GFLOPs）。因此，生成数据消耗

了 10^{23} 量级的 FLOPs，这需要极其恐怖的 Google TPU 算力集群堆叠。

3. 训练样本量与模型参数的比例 (Data-to-Parameter Ratio)

基于上述对局数，我们可以算出 AlphaGo Zero 的实际训练样本规模：

总训练样本量 = $4,900,000$ 局 $\times$ 200 步/局 ≈ 9.8 亿 (约 1 Billion) 个样本

每一个样本是一个 (s_t, π_t, z) 元组。由此可以得出与模型参数量的关键物理比例：

- 训练样本量：~1 Billion (1B)
- 模型参数量：~24 Million (24M)
- 数据-参数比 (Data-to-Parameter Ratio)： $1,000,000,000 / 24,000,000 \approx 40$ 倍

学术启示：高达 40 倍的数据/参数比，意味着 AlphaGo Zero 处于极度“数据充沛”的过参数化训练状态。“小模型 + 海量高质自我对弈数据”把这 24M 参数的特征表达能力压榨到了物理极限，不仅避免了过拟合，还铸就了其超强的泛化能力。作为对比，目前千亿参数的大语言模型 (LLM) 由于高质量语料枯竭，其 Token/参数比例（如 Chinchilla Scaling Laws 所指出的最优比例约为 20 倍）往往勉强达标，难以做到 AlphaGo Zero 这样奢侈的 40 倍高质量监督。

三、凡人算力的救星：KataGo 范式改良

AlphaGo Zero 的“大力出奇迹”证明了算法的上限，但也让科研机构和个人望而却步。后续开源社区（尤其是 **KataGo**）对其进行了关键的算法工程改造，用极少的算力（几十倍效率提升）达到了同等甚至更强的水平。

1. Playout Cap Randomization (访问量上限随机化) —— 击碎“万亿次”推理

痛点：每步死磕 1600 次模拟，大量时间浪费在对局的“无聊/必然”步骤上。

KataGo 的改良：训练生成数据时，约 75%~90% 的回合只给 50~100 次 MCTS 模拟，只在剩下的 10%~25% 回合给 800~1000 次模拟以获得高质量的深度搜索（用于计算 Value 目标和高智商战术）。

结果：单局推理次数从 $200 \times 1600 = 320,000$ 锐减到约 40,000，直接提速将近 10 倍！且这种随机化增加了数据的多样性，起到了极好的正则化作用。

2. TD-Bootstrap 作为辅助价值目标 (Auxiliary Value Target)

痛点： AGZ 使用纯 MC（只有终局 1 bit 的 ± 1 ），对于一局 200 步的棋，这个信号极度稀疏且方差巨大。开头几步的预测极其随机，收敛极慢。

KataGo 的改良： 虽保留终局 MC 目标，但额外引入 **TD (时序差分) 回报**，强迫当前的预测去匹配 *未来几步（如 $t+N$ ）的 MCTS Q 值*。把短期的确定性（低方差）借给了长期的价值网络。

结果： 价值网络的收敛速度提升了数倍，在模型训练极早期就能有效分辨好坏棋。

3. 多任务学习 (Multi-Task Learning)：压榨每一滴环境信息

痛点： AGZ 对于一整局 19×19 棋盘，最后只反馈一个胜负 ($+1/-1$)。网络在盲人摸象。

KataGo 的改良： 强迫网络预测更丰富的局部环境信息。

- **所有权预测 (Ownership)：** 预测终局时每个交叉点属于谁（361 维的密集标签），强制网络理解“地盘”。
- **分数预测 (Score)：** 不仅预测胜负，还要预测赢/输多少目（输出一个分数分布），提供更平滑的梯度信号。

物理类比： 就像 QCD 中，如果只测量总散射截面（单一标量）去反推强子内部结构极度困难；但如果能测出末态的所有粒子能动量分布（多任务局部预测），反推核子结构函数（网络特征表示）就会快得多。

四、低算力外挂 Heuristic 必须遵循的数学框架：重要性采样 (Importance Sampling)

在个人算力极其受限、或者模型极早期阶段时，我们往往需要手动设计一些 Heuristic（例如：子力优势计算器、快速目数估算器）来强行引导树的搜索。但这里潜伏着一个致命的数学陷阱。

1. 强加 Heuristic 的数学危机：破坏无偏性

原版 MCTS 的卓越之处在于它是**渐进无偏 (Asymptotically Unbiased)** 的。如果我们粗暴地把人工的“子力优势”加到 PUCT 公式的 Q 值或 P 值中，树的采样分布（访问量 $\$N\$$ ）就

会被人类的偏见永久性扭曲，导致最终输出的 π 分布严重有偏，进而带偏整个自我强化闭环。

2. 正确做法：重要性采样 (Importance Sampling)

为了在“加速搜索”和“保持无偏”之间取得完美平衡，必须使用蒙特卡洛方法中的核心武器：重要性采样。

- 目标分布 $p(x)$ ：原版无偏的 MCTS 搜索分布。
- 提议分布 $q(x)$ ：叠加了“子力优势/目数估算”等 Heuristic 后的有偏搜索分布（它能更快发现好棋，方差小）。

在 MCTS 的 Backup（回传）和最终生成策略 π 时，不能直接使用原本的均匀加权（ $Q = W/N$ ），而是必须为每个采样的叶节点引入**重要性权重 (Importance Weight)**：

$$w_i = p(x_i) / q(x_i)$$

通过权重补偿： $Q = \sum (w_i \cdot v_i) / \sum w_i$ 。这样，我们既利用了人类 Heuristic 让搜索树迅速朝着“吃子、占地”等有意义的分支生长（提升采样效率），又通过数学上的 Reweighting 保证了最终提取的 Q 值和 π 分布的期望值是**绝对无偏的**。

3. 与物理学的深度共鸣 (Lattice QCD / VMC)

💡 罗院士一定会心领神会的点：这与格点量子色动力学 (Lattice QCD) 和变分蒙特卡洛 (VMC) 中的操作完全同构！在计算路径积分时，我们绝不可能用均匀分布去盲目采样组态（那样算到宇宙毁灭也无法收敛）。我们必然会构造一个包含物理直觉的 **Trial Wavefunction** 或修改过的 Action 来做 Metropolis-Hastings 采样（即 Heuristic 提议分布 q ），然后通过 **Reweighting（重新加权）** 恢复出真实的物理可观测量期望。将 Heuristic 作为提议分布而非绝对真理，是保持数学纯洁性的唯一法门。

五、总结对比

维度	AlphaGo Zero	KataGo (优化后)
数据生成效率	极低（固定1600次/步）	极高（动态 50~800次/步，省近10倍算力）

价值(v)信号源	纯终局 MC (1 bit, 极度稀疏, 方差大)	终局 MC + 局部 TD Bootstrap (密集, 方差小)
辅助任务	无, 网络自己悟	预测所有权、预测具体比分, 密集特征监督
收敛到高水平速度	需要 Google 级别 TPU 跑数天/数周	单块/几块民用高端显卡 几周即可追平早期AGZ

致罗院士的讲解重点：

AlphaGo Zero 的突破在于**思想的纯粹性**（抛弃人类知识，用 MCTS 作为策略迭代算子闭环）；但其工程实现是暴力的（万亿次推理）。实际落地和物理/超算领域的启发是：**纯粹的 MC 算法方差过大、耗时太长，最终还是需要用 TD 截断（Bootstrap）、动态算力分配（Playout Cap）以及辅助标量场（所有权预测）等工程/物理直觉手段来收敛和落地。**