

AlphaGo Zero 算力估算与 KataGo 进化范式

模型参数、推理算力与重要性采样分析

重点议题：

- AlphaGo Zero 模型参数量精算
- 算力黑洞：天文数字的推理次数估算
- 训练样本量与模型参数比例 (Data-to-Parameter Ratio)
- 低算力外挂 Heuristic 的数学框架 (重要性采样)

1. AlphaGo Zero 模型参数量精算

共享特征提取层：双头残差网络 (ResNet 256通道)

- 输入层：19×19×17，初始卷积 (3×3×256) → 约 3.9 万参数
- 残差块 (20个)：单块约 118 万，20 块共计 → 约 2359 万参数
- 策略头 (Policy Head)：输出 362 维分布 → 约 26 万参数
- 价值头 (Value Head)：输出 1 维标量 → 约 9 万参数

模型版本	总参数量	训练总局数
AGZ (3天版) - 20个残差块	~2400 万 (24M)	490 万局
AGZ (40天版) - 40个残差块	~4750 万 (47.5M)	2900 万局

💡 对比观察：这是典型的“小模型、巨算力”，算力绝大多数被消耗在了搜索（推理）过程，而非单次前向传播计算。

2. 算力黑洞：天文数字的推理次数估算

生成一条训练数据需要极其庞大的 MCTS 模拟，每次模拟都需要调用一次神经网络评估叶节点。

$$\text{推理总次数} = \text{训练总局数} \times \text{每局平均步数} \times \text{每步模拟数}$$

以 AlphaGo Zero (3天 20-block 版) 为例：

- 训练总局数 (Total Games): 4,900,000 局
- 每局平均步数 (Moves/Game): 围棋平均约 200 步
- 每步模拟数 (Sims/Move): 1,600 次

$$4.9\text{M} \times 200 \times 1600 \approx 1.56 \text{ 万亿次前向推理 } (1.56 \times 10^{12})$$

每次推理计算一个 24M 参数的 ResNet (约 10 GFLOPs)。生成数据总共消耗 10^{23} 量级的

3. 训练样本量与模型参数比例 (Data-to-Parameter Ratio)

基于对局数，可计算出真实的训练样本规模 (每个样本是一个 (s_t, π_t, z) 元组):

$$\text{总样本量} = 4,900,000 \text{ 局} \times 200 \text{ 步/局} \approx 9.8 \text{ 亿 (1 Billion)}$$

- 训练样本量: $\sim 1 \text{ Billion (1B)}$
- 模型参数量: $\sim 24 \text{ Million (24M)}$
- 数据-参数比: $1,000,000,000 / 24,000,000 \approx \textbf{40 倍}$

学术启示 (与 LLM 对比):

目前千亿参数的大语言模型 (LLM)，受限于真实世界高质量数据枯竭，往往只能勉强满足 Chinchilla Scaling Laws (约 20 倍的 Token/参数比)。

而 AlphaGo Zero 依靠人工合成的 10 亿无偏高质量对弈样本，达到了奢侈的 **40 倍** 数据/参数比。这种极端的数据充沛度把 24M 参数的特征表达能力压榨到了物理极限，完全免疫过拟合。

4. 低算力外挂 Heuristic 必须遵循重要性采样

在个人算力受限时，我们需要手动设计 Heuristic（如：子力优势、目数估算）来引导树的搜索。但粗暴相加会破坏 MCTS 的无偏性 (Unbiasedness)。

重要性采样 (Importance Sampling) 框架

- 目标分布 $p(x)$ ：原版纯粹无偏的 MCTS 搜索分布。
- 提议分布 $q(x)$ ：叠加人类 Heuristic 后的有偏分布 (收敛快)。

在 MCTS 回传和提取策略时，必须引入**重要性权重**：

$$w_i = p(x_i) / q(x_i) \quad \Rightarrow \quad Q = \Sigma (w_i \cdot v_i) / \Sigma w_i$$

💡 **物理共鸣 (Lattice QCD / VMC)**：这完全等价于在计算路径积分时，构造包含物理直觉的 Trial Action 进行 Metropolis-Hastings 采样 (提议分布 q)，再通过 **Reweighting (重新加权)** 恢复真实的物理观测量，维持数学纯洁性。

5. 凡人算力的救星：KataGo 范式改良

开源社区 (KataGo) 对 AGZ 进行降维打击优化，用极少算力达到同等水平：

- **访问量上限随机化 (Playout Cap Randomization)：**

训练时 90% 的回合仅给 50~100 次模拟，仅 10% 满负荷搜 800 次。单局推理从 32 万次锐减到 4 万次，提速近 10 倍。

- **TD-Bootstrap 辅助价值目标：**

AGZ 的纯 MC 信号极度稀疏 (1 bit 终局胜负) 且方差大。KataGo 用未来 MCTS 的 Q 值做 TD Bootstrap 目标，将低方差信号借给价值网络，早期收敛极快。

- **多任务学习 (Multi-Task Learning)：**

预测领地所有权 (361 维密集标签) 和具体比分差。不仅测总截面，还要测多粒子末态分布，快速反演内部结构。

6. 总结对比

维度	AlphaGo Zero	KataGo (优化后)
数据生成效率	极低（固定 1600次/步）	极高（动态 50~800次/步，省近10倍）
价值(v)信号源	纯终局 MC (1 bit, 极稀疏, 方差大)	终局 MC + 局部 TD Bootstrap
辅助任务	无，网络自己悟	预测所有权、具体比分 (密集监督)
数学纯洁性 vs 效率	原教旨主义的无偏闭环	重要性采样 + 算力动态分配
收敛到高水平速度	Google 级别 TPU 集群跑数天	高端民用显卡数周即可追平早期AGZ